

Professional Role Redesign in the Age of Generative AI

*A framework for identifying automation, augmentation
and distinctive human value*

ORIGINAL ACADEMIC TITLE

*Rediseño de puestos profesionales ante la adopción de IA generativa:
un modelo para identificar automatización, aumento y valor humano diferencial*

Coro Hernando de Larramendi Varela

Master's Degree in Artificial Intelligence and Innovation · Founderz

August 2026

*Theoretical and applied work. The application to the Project Manager role is exploratory and does not constitute
empirical validation of the model.*

Resumen

La adopción de inteligencia artificial generativa está modificando la distribución de tareas en los puestos profesionales y ampliando el conjunto de actividades cognitivas susceptibles de ser automatizadas o aumentadas. La literatura reciente muestra ganancias de productividad relevantes, pero también efectos heterogéneos según la tarea, el contexto y el nivel de experiencia. Este trabajo sostiene que la evaluación organizativa de la IA no debería limitarse a la productividad inmediata: algunas tareas desempeñan además una función formativa, porque permiten adquirir criterio, reconocimiento de patrones, comprensión contextual, autonomía y capacidad de supervisión. Se propone un modelo 4V de análisis de tareas compuesto por Viabilidad de Automatización (VA), Valor Humano Diferencial (VHD), Valor de Construcción de Expertise (VCE) y Riesgo de Delegación (RD). El modelo incorpora asimismo el concepto de Experiencia Crítica de Desarrollo (ECD) para identificar los componentes de una tarea que contribuyen de manera significativa al desarrollo profesional. Como demostración, se aplica de forma exploratoria a quince tareas del rol de Project Manager y se analizan en profundidad el reporting de estado, la gestión de riesgos y la gestión de incidencias y excepciones. El trabajo concluye que la estrategia adecuada no consiste en preservar tareas por inercia ni en automatizar por defecto, sino en rediseñar deliberadamente la colaboración humano-IA, la supervisión y las experiencias de aprendizaje. Se propone, finalmente, un proceso de implantación organizativa y un conjunto de salvaguardas de Responsible AI. La principal limitación es la ausencia de validación empírica, que se plantea como línea futura mediante entrevistas, encuesta, validación por expertos y aplicaciones organizativas reales.

Palabras clave: inteligencia artificial generativa; rediseño de puestos; automatización; augmentation; expertise; aprendizaje en el trabajo; Project Management; Responsible AI.

Abstract

Generative artificial intelligence is reshaping the distribution of tasks within professional roles and expanding the range of cognitive activities that can be automated or augmented. Recent evidence reports substantial productivity gains, but also heterogeneous effects across tasks, contexts and experience levels. This thesis argues that organizational AI assessment should not focus solely on short-term productivity: some tasks also perform a developmental function by helping professionals build judgment, pattern recognition, contextual understanding, autonomy and supervisory capability. The thesis proposes a 4V task-analysis model comprising Automation Viability, Differential Human Value, Expertise-Building Value and Delegation Risk. It also introduces the concept of Critical Development Experience to identify the learning components embedded in tasks. The model is applied exploratorily to fifteen Project Manager tasks, with deeper analysis of status reporting, risk management, and issue/exception management. The thesis concludes that organizations should neither preserve tasks by default nor automate them by default; instead, they should deliberately redesign human-AI collaboration, oversight and learning experiences. An organizational implementation process and Responsible AI safeguards are proposed. The main limitation is the lack of empirical

validation, which is left for future research through interviews, surveys, expert validation and real organizational applications.

Keywords: generative artificial intelligence; job redesign; automation; augmentation; expertise; workplace learning; project management; Responsible AI.

Índice

1. Introducción
 2. Inteligencia artificial generativa y transformación del trabajo profesional
 3. Expertise, aprendizaje profesional y construcción de criterio
 4. Metodología y diseño del modelo
 5. Modelo 4V para el rediseño de tareas profesionales
 6. Aplicación exploratoria al rol del Project Manager
 7. Propuesta de implementación, Responsable AI y gobernanza
 8. Conexión con IKIG-AI y AI THINK
 9. Discusión, limitaciones y futuras líneas de investigación
 10. Conclusiones
- Referencias
- Anexo A. Matriz exploratoria de tareas de Project Management

1. Introducción

1.1. Planteamiento del problema

La inteligencia artificial generativa (IAGen) está modificando de forma acelerada la manera en que se distribuyen, ejecutan y supervisan numerosas tareas profesionales. Actividades que hasta hace pocos años exigían una participación humana directa -redactar, resumir, analizar información, elaborar borradores, estructurar documentación, generar escenarios o proponer alternativas- pueden hoy ser asistidas o parcialmente automatizadas mediante modelos generativos. Este cambio afecta especialmente a los trabajos intensivos en conocimiento, donde buena parte de la actividad profesional se articula mediante lenguaje, información digital y decisiones apoyadas en documentos.

La evidencia empírica disponible muestra beneficios reales de productividad, pero también importantes diferencias por tarea, contexto y nivel de experiencia. Brynjolfsson, Li y Raymond (2025), en un estudio con 5.172 agentes de atención al cliente, encuentran un incremento medio de productividad de aproximadamente el 15 %, con mayores beneficios para trabajadores menos experimentados. Noy y Zhang (2023) observan asimismo mejoras de velocidad y calidad en tareas de escritura profesional. En consultoría, Dell'Acqua et al. (2026) muestran que los efectos dependen de si la tarea se encuentra dentro o fuera de una frontera tecnológica irregular: la IA puede mejorar el desempeño en unas actividades y perjudicarlo en otras aparentemente próximas. En desarrollo de software, Cui et al. (2026) encuentran aumentos significativos de tareas completadas en tres experimentos de campo.

Estos resultados hacen insuficiente una pregunta genérica del tipo «¿qué profesiones sustituirá la IA?». El análisis debe descender al nivel de tarea. La OIT (Gmyrek et al., 2025) adopta precisamente un enfoque granular y concluye que, dado que la mayoría de las ocupaciones combinan tareas con distintos grados de exposición y continúan necesitando aportación humana, la transformación de los puestos es un escenario más probable que su eliminación completa.

Sin embargo, tampoco basta con preguntar qué tareas son técnicamente automatizables. Los puestos profesionales cumplen una función productiva, pero también una función de desarrollo. Al realizar tareas reales, las personas adquieren conocimiento del contexto, observan excepciones, reciben feedback, calibran decisiones, reconocen patrones y progresan hacia niveles superiores de autonomía. La automatización puede eliminar trabajo de bajo valor operativo y, a la vez, transformar las experiencias mediante las que se construía expertise. Del mismo modo, la IA puede acelerar el aprendizaje al proporcionar ejemplos, feedback, acceso a patrones expertos y apoyo cognitivo. El efecto no es unívoco: depende del diseño del trabajo.

Este TFM aborda esa tensión proponiendo un modelo de análisis que combine productividad presente, valor humano, desarrollo de expertise y riesgo de delegación. Su finalidad no es proteger tareas por nostalgia ni frenar la adopción de IA, sino ayudar a decidir qué conviene automatizar, qué conviene aumentar y qué experiencias humanas deben preservarse, sustituirse o rediseñarse.

1.2. Pregunta de investigación y objetivos

La pregunta principal de investigación es:

¿Cómo pueden las organizaciones rediseñar los puestos profesionales ante la adopción de inteligencia artificial generativa, identificando qué tareas pueden automatizarse, cuáles deben aumentarse mediante IA y dónde reside el valor humano diferencial que conviene preservar o reforzar?

Se plantean dos preguntas secundarias: (1) ¿cómo debería considerarse el valor formativo de las tareas cuando la IA generativa automatiza actividades que tradicionalmente contribuían al desarrollo de expertise profesional?; y (2) ¿qué riesgos aparecen cuando la correcta supervisión de outputs generados por IA requiere una expertise cuyo proceso de adquisición está siendo transformado por la propia automatización?

El objetivo general es diseñar un modelo de análisis y rediseño de puestos profesionales que permita evaluar el impacto de la IAGen sobre las tareas de un puesto e identificar oportunidades de automatización, aumento mediante IA y preservación o desarrollo del valor humano diferencial y de la expertise profesional.

- Analizar cómo la IAGen está modificando la distribución de tareas en el trabajo profesional.
- Identificar factores que condicionan la viabilidad de automatizar o aumentar una tarea mediante IA.
- Analizar los componentes del trabajo que mantienen valor humano diferencial: juicio, contexto, conocimiento tácito, interacción, responsabilidad y gestión de excepciones.
- Examinar el papel que determinadas tareas y experiencias desempeñan en la construcción de expertise.
- Analizar los riesgos asociados a delegar en IA tareas cuya correcta supervisión requiere experiencia profesional significativa.
- Proponer un modelo práctico de análisis de tareas que oriente decisiones de automatización, aumento humano-IA o intervención humana significativa.
- Aplicar de forma exploratoria el modelo al rol del Project Manager.

1.3. Aportación y alcance

La aportación principal es el modelo 4V, integrado por Viabilidad de Automatización (VA), Valor Humano Diferencial (VHD), Valor de Construcción de Expertise (VCE) y Riesgo de Delegación (RD). El modelo incorpora el concepto de Experiencia Crítica de Desarrollo (ECD), definido como una experiencia profesional cuya realización contribuye de forma relevante al desarrollo de capacidades necesarias para niveles posteriores de competencia, autonomía o responsabilidad.

El trabajo es teórico-aplicado y exploratorio. No se realiza una validación empírica mediante entrevistas o encuesta. En consecuencia, las valoraciones aplicadas a Project Management son hipótesis analíticas fundamentadas en literatura y razonamiento estructurado, no resultados generalizables. Esta delimitación permite concentrar el TFM en la formulación del modelo, su lógica de uso y su potencial organizativo.

2. Inteligencia artificial generativa y transformación del trabajo profesional

2.1. De la exposición ocupacional al análisis por tareas

La IAGen amplía la automatización desde actividades rutinarias y estructuradas hacia tareas cognitivas que utilizan lenguaje natural, conocimiento codificado y producción de contenido. Sin embargo, la exposición tecnológica de una ocupación no equivale a automatización efectiva ni a desplazamiento laboral. Gmyrek et al. (2025) distinguen niveles de exposición a partir de casi 30.000 tareas y subrayan que la mayoría de las ocupaciones seguirá requiriendo aportación humana. Por ello, el análisis de tareas ofrece una unidad más adecuada para decisiones organizativas que la ocupación completa.

Adoptar la tarea como unidad de análisis permite separar actividades con distinta estructura, verificabilidad, dependencia contextual, necesidad de interacción y gravedad del error. También evita decisiones binarias del tipo «automatizar o no automatizar un puesto», que ocultan la heterogeneidad del trabajo profesional.

2.2. La frontera tecnológica irregular

Dell'Acqua et al. (2026) conceptualizan la “jagged technological frontier”: la capacidad de una IA no avanza uniformemente y puede producir mejoras en unas tareas y deterioro en otras dentro del mismo flujo de conocimiento. En su experimento preregistrado con 758 profesionales de consultoría, el uso de GPT-4 mejoró velocidad, volumen y calidad en tareas situadas dentro de la frontera, pero generó peores decisiones cuando los participantes confiaban en la herramienta para tareas fuera de ella. Este resultado fundamenta la necesidad de evaluar la viabilidad de automatización a nivel de actividad concreta y de incorporar verificabilidad y consecuencias del error, no solo la posibilidad de generar un output plausible.

2.3. Productividad y heterogeneidad por experiencia

Los estudios de campo disponibles muestran que la IAGen puede incrementar de manera significativa la productividad. Brynjolfsson et al. (2025) encuentran mejoras especialmente elevadas entre agentes menos experimentados y de menor rendimiento. Noy y Zhang (2023) muestran que ChatGPT reduce el tiempo y mejora la calidad media en tareas profesionales de escritura. Cui et al. (2026), a partir de tres experimentos aleatorizados con 4.867 desarrolladores, hallan un incremento agregado relevante de tareas completadas. Estos resultados apoyan una lectura de augmentation: la IA puede difundir patrones, reducir barreras de acceso a conocimiento y elevar el “suelo” del desempeño.

Pero mejorar el output no significa necesariamente haber adquirido la capacidad subyacente. Un profesional puede producir un resultado de mayor calidad gracias a la IA sin haber desarrollado el mismo nivel de comprensión, diagnóstico o autonomía que se requería antes. La distinción entre desempeño asistido y capacidad retenida será importante para analizar el VCE.

2.4. Acceso tecnológico versus rediseño del trabajo

Dillon et al. (2025) estudian el uso de herramientas generativas durante seis meses en 66 empresas y 7.137 trabajadores del conocimiento. Los usuarios ahorraron tiempo, especialmente en correo electrónico, pero no se observaron cambios detectables en la cantidad o composición global de tareas. Esta evidencia permite distinguir tres niveles: acceso a una herramienta, uso individual y rediseño organizativo. El TFM se sitúa en el tercero: cómo modificar tareas, responsabilidades, supervisión y aprendizaje una vez que la IA es capaz de intervenir en el trabajo.

2.5. Automatización, aumento y modos de colaboración

En este trabajo, automatización describe situaciones en las que la IA asume una parte sustancial de la ejecución; aumento describe situaciones en las que la persona conserva la responsabilidad principal y utiliza IA para ampliar velocidad, análisis o calidad. Entre ambos extremos existe un continuo de delegación. Para fines de diseño se distinguen cuatro modalidades: human-first (el profesional formula primero su análisis), co-creación (persona e IA trabajan iterativamente), AI-first (la IA genera una propuesta que el profesional interpreta y revisa) y delegation-first (la IA realiza la mayor parte de la actividad y la persona interviene principalmente por supervisión o excepción).

Esta secuencia importa porque dos profesionales pueden “usar IA” en la misma tarea y vivir experiencias cognitivas muy diferentes. Un modelo de rediseño debe considerar no solo qué porcentaje de la tarea hace la IA, sino dónde se sitúa la intervención humana dentro del proceso de razonamiento y decisión.

3. Expertise, aprendizaje profesional y construcción de criterio

3.1. Expertise y oportunidades de práctica

La expertise no es equivalente a años de experiencia. Rousseau y Stouten (2025) la describen como estructuras jerárquicas de conocimiento específicas de dominio que se desarrollan con educación, entrenamiento y oportunidades de práctica y aprendizaje. Esta perspectiva permite analizar la automatización desde una pregunta distinta: no solo qué conocimiento posee hoy una persona, sino qué experiencias necesita para desarrollar las capacidades que se requerirán mañana.

3.2. Aprendizaje informal en el trabajo

Una parte sustancial del desarrollo profesional ocurre fuera de programas formales. Tannenbaum y Wolfson (2022) revisan la literatura sobre aprendizaje informal “en el terreno” y proponen cinco condiciones facilitadoras: capability, awareness, motivation, opportunity y support. Eraut (2004) también destaca el aprendizaje derivado de participación, observación, resolución de problemas, interacción y reflexión. Por tanto, automatizar una tarea puede modificar una oportunidad de aprendizaje, aunque no necesariamente reducirla: puede

sustituir una experiencia de bajo valor por otra más rica si el trabajo se rediseña deliberadamente.

3.3. Project managers: aprendizaje mediante experiencia y reflexión

La literatura específica de Project Management refuerza esta idea. Savelsbergh, Havermans y Storm (2016), en un estudio multimétodo con 31 project managers, encuentran que el aprendizaje profesional se produce principalmente de forma informal on-the-job y que la reflexión individual y con otros facilita convertir experiencia en aprendizaje. Para el caso de aplicación de este TFM, este resultado es particularmente importante: una tarea puede ser una unidad productiva y, a la vez, un vehículo de aprendizaje contextual.

3.4. Participación, apprenticeship y tecnología

La literatura sobre apprenticeship muestra que el desarrollo profesional implica observación, participación guiada, feedback y progresión de responsabilidad. Fuller y Unwin (2003) distinguen entre entornos expansivos, que ofrecen oportunidades de participación y crecimiento, y restrictivos, que limitan esas oportunidades. La automatización podría convertir una trayectoria expansiva en restrictiva si elimina el acceso de perfiles junior a situaciones significativas; pero también podría hacer lo contrario si libera tiempo de tareas puramente administrativas y permite participar antes en análisis y decisiones de mayor nivel.

Beane y Anthony (2024) ofrecen evidencia particularmente relevante sobre este punto. En estudios etnográficos comparativos en cirugía urológica y banca de inversión, muestran cómo la llegada de nuevas tecnologías reorganiza las relaciones entre seniors y juniors y cómo varios patrones de “inverted apprenticeship” pueden perjudicar el aprendizaje de los miembros más junior. El mecanismo no es la tecnología en abstracto, sino la reconfiguración de interacciones y oportunidades de práctica alrededor de ella.

3.5. Feedback, error y excepciones

La construcción de criterio requiere ciclos de acción, resultado, feedback, reflexión y ajuste. La revisión de Anseel y Sherf (2025) muestra que el feedback no produce automáticamente mejora: su efecto depende de la forma en que se recibe y procesa. En tareas profesionales, formular una hipótesis antes de consultar a la IA puede permitir comparar razonamiento propio y propuesta artificial; recibir primero una respuesta completa de IA puede reducir ese contraste si la persona se limita a aceptarla. Por ello, el momento de intervención de la IA forma parte del diseño del aprendizaje.

Las excepciones tienen especial valor formativo porque obligan a reconocer cuándo el procedimiento estándar deja de ser suficiente. En Project Management, desviaciones, conflictos, dependencias ocultas, riesgos imprevistos y cambios de prioridad permiten desarrollar diagnóstico, anticipación y juicio contextual. Si los sistemas filtran o resuelven estas situaciones antes de que el profesional las vea, puede desaparecer exposición valiosa; si las convierten en simulaciones, casos comparables o feedback estructurado, pueden ampliar el aprendizaje.

3.6. Experiencia Crítica de Desarrollo y paradoja de supervisión

Este TFM denomina Experiencia Crítica de Desarrollo (ECD) a una experiencia profesional cuya realización contribuye de forma relevante al desarrollo de una o más capacidades necesarias para niveles posteriores de competencia, autonomía o responsabilidad. La ECD no coincide necesariamente con una tarea completa. Por ejemplo, “preparar un informe de estado” contiene producción textual, selección de información, interpretación de desviaciones, decisión sobre escalado y adaptación a stakeholders. La IA puede automatizar la producción sin eliminar las ECD cognitivas, siempre que estas se rediseñen explícitamente.

De esta distinción deriva la llamada paradoja de supervisión: la ejecución puede dejar de ser necesaria para producir un resultado, mientras que la experiencia asociada siga siendo necesaria para detectar cuándo el resultado es incorrecto, incompleto o contextualmente inadecuado. Si los futuros supervisores dejan de vivir las experiencias que construyen esa capacidad, una organización puede aumentar eficiencia hoy y debilitar su capacidad de control mañana. Esta es una posibilidad a gestionar, no una consecuencia inevitable.

El principio de diseño resultante es sencillo: no preservar tareas por nostalgia, sino identificar las experiencias que construyan capacidades y decidir si deben preservarse, sustituirse o rediseñarse. La unidad óptima de automatización no siempre coincide con la unidad óptima de aprendizaje.

4. Metodología y diseño del modelo

4.1. Enfoque

El TFM adopta un enfoque teórico-aplicado. La construcción del modelo combina una revisión narrativa orientada a problema con síntesis conceptual de cuatro corrientes: (a) evidencia sobre IAGen y productividad/exposición por tareas; (b) human-AI collaboration y riesgos de delegación; (c) expertise, aprendizaje informal y desarrollo profesional; y (d) literatura de Project Management. La selección de fuentes prioriza estudios peer-reviewed, experimentos de campo, revisiones académicas y fuentes institucionales primarias. Los informes profesionales se utilizan únicamente como contexto cuando aportan estándares o práctica sectorial.

No se pretende realizar una revisión sistemática exhaustiva ni una meta-análisis. La finalidad metodológica es construir un marco parsimonioso que sea suficientemente riguroso para orientar decisiones empresariales y, al mismo tiempo, susceptible de validación posterior.

4.2. Propositiones de partida

Proposición	Formulación
P1. Tarea como unidad de análisis	El impacto de la IAGen se comprende mejor a nivel de tarea que a nivel de puesto completo.
P2. Automatización no equivale a sustitución	Una elevada capacidad técnica no implica que la

Proposición	Formulación
	opción óptima sea la automatización completa.
P3. Valor humano diferencial	El valor humano aumenta cuando la tarea depende de juicio, contexto, relaciones, responsabilidad, ambigüedad o excepción.
P4. Valor de construcción de expertise	Algunas tareas poseen valor adicional porque generan experiencias necesarias para capacidades futuras.
P5. Automatización formativamente sensible	Una tarea con VA alta y VCE alto requiere rediseñar explícitamente el aprendizaje asociado.
P6. Paradoja de supervisión	Puede disminuir la necesidad de ejecutar una tarea mientras sigue siendo alta la expertise necesaria para verificarla.
P7. Efecto potencialmente positivo de la IA	La IAGen también puede acelerar aprendizaje mediante feedback, ejemplos, acceso a conocimiento y exposición ampliada.
P8. Dependencia del diseño del trabajo	El efecto final sobre productividad y capacidad profesional depende de cómo se configuran tareas, supervisión, feedback y participación.

4.3. Lógica de construcción

El modelo evita sumar las cuatro dimensiones en un índice único. Una puntuación agregada produciría falsa precisión y permitiría que una dimensión crítica quedara compensada por otra. La lógica propuesta es de perfil: cada tarea se evalúa en cuatro ejes y la recomendación surge de la combinación. Las escalas pueden expresarse cualitativamente (bajo, medio, alto) o cuantitativamente (1-5) en futuras aplicaciones, pero las reglas de decisión deben conservar umbrales de salvaguarda para riesgo, responsabilidad y aprendizaje.

La aplicación exploratoria de este TFM utiliza niveles cualitativos B/M/A. No proceden de una muestra ni representan estimaciones empíricas; sirven únicamente para mostrar cómo funcionaría el modelo.

5. Modelo 4V para el rediseño de tareas profesionales

5.1. V1 - Viabilidad de Automatización (VA)

La VA estima hasta qué punto la IAGen puede ejecutar una parte sustancial de la tarea con calidad, fiabilidad y verificabilidad suficientes. No pregunta simplemente si el modelo “puede generar algo”, sino si la delegación es operativamente razonable.

- Estructura y repetibilidad de la tarea.
- Disponibilidad y calidad de la información necesaria.
- Capacidad actual de la IA para producir el output requerido.
- Necesidad de conocimiento contextual no documentado.
- Facilidad de verificar el resultado.
- Frecuencia y complejidad de excepciones.

Una VA alta no determina por sí sola automatización. Debe cruzarse con VHD, VCE y RD.

5.2. V2 - Valor Humano Diferencial (VHD)

El VHD estima en qué medida el desempeño de la tarea depende de capacidades humanas cuyo valor no se reduce a producir un output formalmente correcto. Incluye juicio contextual, conocimiento tácito, interacción y confianza, negociación, comprensión de intereses, responsabilidad y gestión de excepciones. El concepto no pretende afirmar que estas capacidades sean intrínsecamente imposibles para la IA, sino identificar dónde la contribución humana sigue siendo material para el resultado y para la legitimidad de la decisión.

- Juicio y contextualización.
- Conocimiento tácito y señales no registradas.
- Relación, confianza, influencia o negociación.
- Responsabilidad y accountability.
- Ambigüedad, conflicto de objetivos y trade-offs.
- Gestión de excepciones y consecuencias humanas.

5.3. V3 - Valor de Construcción de Expertise (VCE)

El VCE es la dimensión más diferencial del modelo. Se define como el grado en que la realización activa de una tarea, o de las experiencias contenidas en ella, contribuye al desarrollo de conocimientos, reconocimiento de patrones, criterio, autonomía y capacidades necesarias para responsabilidades superiores.

- Exposición a casos reales, variaciones y excepciones.
- Procesamiento activo: interpretar, diagnosticar, decidir o anticipar.
- Feedback y posibilidad de comparar decisión con resultado.
- Reflexión individual o compartida con profesionales más experimentados.
- Transferencia a responsabilidades de mayor nivel.
- Desarrollo de capacidad para detectar errores u omisiones de humanos o IA.
- Dificultad de sustituir el aprendizaje mediante documentación o formación formal.

Una tarea puede tener VCE alto aunque su componente productivo sea automatizable. En ese caso, la recomendación no es conservar necesariamente la tarea completa, sino identificar sus ECD y crear una experiencia equivalente.

5.4. V4 - Riesgo de Delegación (RD)

El RD estima las consecuencias de delegar sustancialmente la tarea en IA. Incorpora riesgo del output y riesgo organizativo de dependencia.

- Impacto de un error u omisión.
- Reversibilidad de la decisión.
- Privacidad, confidencialidad y sensibilidad de datos.
- Trazabilidad y posibilidad de explicar el resultado.
- Impacto sobre personas, derechos o relaciones.
- Probabilidad de errores plausibles difíciles de detectar.
- Nivel de expertise necesario para verificar.
- Riesgo de pérdida de capacidad, automatización complaciente o dependencia excesiva.

5.5. Perfiles de decisión

Perfil	Patrón orientativo	Respuesta de diseño
Automatizar	VA alta; VHD bajo; VCE bajo; RD controlable	Delegación amplia, controles proporcionados y revisión por excepción.
Aumentar / copiloto	VA media-alta; VHD medio-alto	IA para borradores, análisis o síntesis; humano interpreta y decide.
Human-led	VHD o RD altos	La persona conserva liderazgo y responsabilidad; IA como apoyo limitado.
Automatizar + salvaguarda formativa	VA alta + VCE alto	Automatizar el componente productivo y rediseñar explícitamente las ECD.
Rediseñar/eliminar proceso	Bajo valor total y proceso innecesario	Antes de automatizar, cuestionar si la tarea debe existir.

5.6. Zona de Tensión Automatización-Expertise (ZTAE)

Se denomina Zona de Tensión Automatización-Expertise (ZTAE) a la combinación de VA alta y VCE alto. No implica automáticamente pérdida de expertise: identifica una zona donde una decisión basada exclusivamente en eficiencia sería incompleta. Las tareas situadas en ZTAE exigen preguntar qué ECD contiene la tarea, si la IA reduce o amplía esas experiencias y qué

mecanismo alternativo puede preservar el aprendizaje. La ZTAE es, por tanto, una alerta de diseño y no una prohibición de automatización.

5.7. Principio de verificación

Dentro de RD merece atención la necesidad de expertise para verificar. Cuanto más plausible y difícil de detectar sea un error, mayor debe ser la capacidad del supervisor. Esto conecta la gobernanza técnica con la gestión del talento: no basta con exigir “human in the loop” si el humano carece de tiempo, información, autoridad o expertise suficientes para ejercer una supervisión significativa.

6. Aplicación exploratoria al rol del Project Manager

6.1. Justificación del caso

Project Management es un caso idóneo porque combina tareas documentales y analíticas altamente digitalizadas con actividades de juicio, coordinación, negociación y responsabilidad. Además, la progresión desde perfiles junior hacia roles senior depende de aprender a interpretar desviaciones, anticipar riesgos, manejar conflictos y entender dinámicas organizativas. La literatura específica muestra que el aprendizaje del PM es intensamente experiencial (Savelsbergh et al., 2016). Al mismo tiempo, la adopción de GenAI en PM ya es objeto de investigación empírica y de estandarización profesional. Felicetti et al. (2024) estudian la apropiación de chatbots generativos por project managers, y Li et al. (2026) encuentran que mindfulness y job crafting se relacionan con un uso más efectivo de GenAI. El PMI publicó en 2026 un estándar específico para IA en portfolio, program y project management, con énfasis en responsabilidad, supervisión y uso ético.

6.2. Taxonomía de tareas

#	Tarea	VA	VHD	VCE	RD	Orientación exploratoria
1	Definir alcance, objetivos y criterios de éxito	M	A	A	A	Human-led + IA de apoyo
2	Descomponer y planificar el trabajo	A	M-A	A	M-A	Aumentar + salvaguarda formativa
3	Elaborar y mantener el cronograma	A	M	M-A	M	Aumentar / automatizar partes
4	Realizar estimaciones de esfuerzo, duración y coste	M-A	A	A	A	Human-led / co-creación

#	Tarea	VA	VHD	VCE	RD	Orientación exploratoria
5	Asignar y coordinar recursos	M	A	A	A	Human-led + apoyo analítico
6	Monitorizar progreso y detectar desviaciones	A	A	A	A	Aumentar + salvaguarda formativa
7	Preparar y comunicar estado del proyecto	A	M-A	A	M-A	Automatizar producción + preservar interpretación
8	Preparar y seguir reuniones, decisiones y acciones	A	M	M	M	Automatizar captura + humano en significado
9	Identificar, evaluar y priorizar riesgos	A	A	A	A	Co-creación / human-led en prioridad
10	Gestionar incidencias, bloqueos y excepciones	M	A	A	A	Human-led + IA de apoyo
11	Evaluar y gestionar cambios	M-A	A	A	A	Human-led / co-creación
12	Comunicar y adaptar información a stakeholders	A	A	A	M-A	Aumentar; humano conserva contexto y responsabilidad
13	Gestionar expectativas y alineamiento	M	A	A	A	Human-led
14	Negociar y gestionar conflictos	B-M	A	A	A	Human-led
15	Analizar resultados, errores y lessons learned	A	A	A	M-A	Co-creación + reflexión humana

Nota: B = bajo; M = medio; A = alto. La tabla es una demostración conceptual, no una medición empírica.

6.3. Caso 1: preparar y comunicar el estado del proyecto

La elaboración de status reports presenta VA alta en sus componentes de producción: resumir información, estructurar un documento, generar texto, comparar indicadores y adaptar formato. Sin embargo, la tarea contiene ECD relevantes: contrastar plan y realidad, detectar incoherencias, distinguir señal de ruido, diagnosticar causas, priorizar asuntos y decidir qué escalar. Estas actividades contribuyen al desarrollo de interpretación y juicio ejecutivo.

Un diseño delegation-first, en el que la IA toma todas las fuentes y produce un informe que el junior solo revisa, puede mejorar velocidad pero reducir procesamiento activo. Una alternativa formativamente más robusta sería: (1) el profesional selecciona primero los cambios y riesgos que considera materiales; (2) la IA genera o mejora la redacción; (3) se comparan diferencias; (4) el PM senior proporciona feedback sobre prioridades y escalado. De este modo se automatiza producción sin eliminar la ECD.

Dimensión	Valoración exploratoria	Razón principal
VA	Alta	Síntesis, estructura y redacción son ampliamente asistibles.
VHD	Medio-alto	La relevancia, el escalado y la adaptación dependen del contexto.
VCE	Alto	Desarrolla interpretación, priorización, causalidad y comunicación ejecutiva.
RD	Medio-alto	Una omisión plausible puede ocultar problemas y el supervisor debe comprender el proyecto.

6.4. Caso 2: identificar, evaluar y priorizar riesgos

La identificación de riesgos es un ejemplo claro de complementariedad. La IAGen puede ampliar el espacio de escenarios, sugerir categorías, recuperar patrones conocidos y generar preguntas. Esto eleva VA. Sin embargo, la materialidad de un riesgo depende de contexto, dependencias, señales débiles, intereses, información no documentada y experiencia. El VHD y el RD son, por ello, altos.

El VCE también es alto: anticipar riesgos obliga a formular hipótesis sobre el futuro y permite posteriormente comparar previsión y resultado. Esa calibración es central para construir criterio. Un diseño adecuado sería human-first o co-creación: el PM formula riesgos iniciales, la

IA amplía y desafía el análisis, y el equipo decide probabilidad, impacto, señales y respuesta. Delegar completamente la identificación podría aumentar cobertura superficial y, al mismo tiempo, reducir el aprendizaje de anticipación.

Dimensión	Valoración exploratoria	Razón principal
VA	Alta	La IA puede generar escenarios y ampliar categorías de riesgo.
VHD	Alto	La prioridad depende de contexto, señales débiles y trade-offs.
VCE	Alto	Construye anticipación, calibración, causalidad y pensamiento sistémico.
RD	Alto	Riesgos omitidos o mal priorizados pueden tener consecuencias materiales.

6.5. Caso 3: gestionar incidencias, bloqueos y excepciones

La gestión de incidencias presenta una VA menor que el reporting porque la información relevante suele estar incompleta y el problema puede cambiar mientras se analiza. La IA puede ayudar a estructurar causas, sugerir hipótesis, comparar precedentes y generar opciones, pero la decisión exige comprender restricciones reales, relaciones, urgencia y consecuencias. VHD y RD son altos.

Desde la perspectiva de expertise, las incidencias y excepciones son especialmente valiosas: exponen al profesional a causalidad real, decisiones bajo presión y consecuencias. Por ello, la estrategia recomendada es human-led con IA como apoyo. La organización debería evitar que los juniors queden excluidos sistemáticamente de estas situaciones por una combinación de automatización y concentración de crisis en perfiles senior. Una alternativa es incorporar observación guiada, post-mortems, simulaciones y participación progresiva.

Dimensión	Valoración exploratoria	Razón principal
VA	Media	La IA ayuda a diagnosticar, pero suele carecer de información contextual completa.
VHD	Alto	Se requiere juicio, coordinación, confianza y decisión bajo incertidumbre.
VCE	Alto	Las excepciones construyen diagnóstico, autonomía y criterio.

Dimensión	Valoración exploratoria	Razón principal
RD	Alto	Errores de diagnóstico o escalado pueden amplificar el problema.

6.6. Rediseño de la trayectoria junior-senior

La aplicación sugiere que el principal riesgo no es que desaparezca “trabajo junior” como categoría, sino que cambie la secuencia de experiencias mediante la que se adquiere criterio. Algunas actividades de entrada -minutas, reporting, actualización de planes- pueden automatizarse intensamente. El reto es separar su componente administrativo de las ECD que contenían: observar decisiones, detectar desviaciones, interpretar prioridades, hablar con stakeholders, cometer errores pequeños y recibir feedback.

Una trayectoria rediseñada podría acelerar el acceso a experiencias de mayor valor mediante cuatro mecanismos: práctica human-first en tareas seleccionadas; revisión comparativa entre análisis humano y output de IA; participación temprana en reuniones y excepciones con mentoring; y simulaciones/post-mortems basados en casos reales. La productividad liberada por la IA se convertiría así en “capacidad de aprendizaje” en lugar de simple reducción de esfuerzo.

7. Propuesta de implementación, Responsable AI y gobernanza

7.1. Proceso organizativo de aplicación

Fase	Acción
1. Mapear tareas	Descomponer el rol en 10-20 tareas con suficiente granularidad y distinguir producción, cognición, relación y aprendizaje.
2. Evaluar 4V	Valorar cada tarea mediante workshop con titulares del puesto, managers y perfiles de distinta seniority.
3. Identificar ECD	Preguntar qué capacidades se desarrollaban al hacer la tarea y qué experiencias concretas las generaban.
4. Diseñar colaboración	Elegir human-first, co-creación, AI-first o delegation-first según perfil y riesgo.
5. Diseñar salvaguardas	Definir revisión, escalado, privacidad, trazabilidad, responsables y límites de uso.
6. Rediseñar aprendizaje	Si desaparece una ECD, sustituirla por práctica guiada, simulación, rotación, mentoring o reflexión estructurada.

Fase	Acción
7. Pilotar y medir	Medir productividad, calidad, errores, tiempo de revisión, aprendizaje y percepción de autonomía.
8. Revisar	Actualizar el diseño conforme cambian las capacidades de la IA y la experiencia del equipo.

7.2. Responsable AI como condición del rediseño

El uso responsable de IA no debe reducirse a cumplimiento documental. En el contexto del trabajo profesional, implica asegurar que la persona conserva capacidad real para comprender, cuestionar y escalar resultados. El estándar de PMI para IA en portfolio, program and project management (PMI, 2026) refuerza principios de responsabilidad, transparencia, supervisión y uso ético. A nivel organizativo, el modelo 4V integra estos principios principalmente a través de RD y VHD.

Las salvaguardas mínimas para una implantación incluyen:

- Definir qué datos pueden introducirse en herramientas de IA y bajo qué condiciones.
- Mantener trazabilidad de outputs relevantes y decisiones humanas asociadas.
- Asignar responsable humano con autoridad real para aceptar, modificar o rechazar la recomendación.
- Ajustar la intensidad de supervisión al impacto y dificultad de verificación.
- Evitar que “human in the loop” sea una etiqueta vacía: el revisor necesita tiempo, contexto y expertise.
- Informar a los equipos sobre capacidades y limitaciones del sistema, incluida la posibilidad de errores plausibles.
- Revisar efectos sobre carga de trabajo, autonomía, aprendizaje y distribución de oportunidades.
- Incluir a los titulares del puesto y diferentes niveles de seniority en el proceso de rediseño.

7.3. Riesgos específicos del modelo

El propio uso del 4V puede generar riesgos si se interpreta de forma mecanicista. Una puntuación alta de VA puede utilizarse como justificación de reducción de puestos sin analizar VHD o VCE; un valor alto de VCE puede convertirse en excusa para conservar trabajo ineficiente; y los ratings pueden reflejar intereses de quienes participan. Por ello, el modelo debe utilizarse como herramienta de deliberación, no como algoritmo de decisión. Las valoraciones deben documentar evidencia, incertidumbre y desacuerdos.

7.4. Métricas de impacto

Una implantación responsable debería medir resultados en dos horizontes. En el corto plazo: tiempo, coste, calidad, errores, retrabajo y satisfacción. En el medio plazo: autonomía, capacidad

de detectar errores, movilidad hacia tareas de mayor responsabilidad, tiempo de mentoring, aprendizaje percibido, exposición a ECD y disponibilidad de expertos capaces de supervisar. Esta doble métrica refleja la tesis central del trabajo: optimizar productividad presente y capacidad profesional futura.

8. Conexión con IKIG-AI y AI THINK

8.1. IKIG-AI: propósito y coherencia del proyecto

El proyecto conecta con IKIG-AI porque sitúa la tecnología dentro de un propósito profesional y social. El interés personal se encuentra en comprender cómo la IA transforma el trabajo experto y cómo puede utilizarse sin degradar aquello que hace valiosa la experiencia humana. La base de conocimiento combina trabajo intensivo en lenguaje, gestión de proyectos, calidad, procesos, comunicación internacional y uso aplicado de IA. La necesidad del entorno es creciente: organizaciones de todos los sectores están incorporando IAGen y necesitan criterios que vayan más allá de “qué puede automatizarse”. La dimensión sostenible reside en convertir este análisis en una metodología reutilizable para rediseño de roles, transformación del talento y adopción responsable.

Dimensión IKIG-AI	Aplicación al TFM
Lo que me mueve	Comprender y mejorar la relación entre IA, trabajo experto y desarrollo profesional.
Lo que sé hacer	Analizar procesos, lenguaje, calidad, proyectos, stakeholders e IA aplicada.
Lo que el mundo necesita	Adoptar IA con productividad sin erosionar criterio, responsabilidad ni aprendizaje.
Lo que puede ser sostenible	Metodología de assessment y rediseño aplicable a organizaciones y distintos roles.

8.2. AI THINK como lógica de diseño

El enfoque AI THINK se utiliza como guía práctica, no como elemento ornamental. El problema se formula desde impacto organizativo; la tecnología se evalúa según capacidad real y no por novedad; el diseño es human-centered; la ética se integra en supervisión, privacidad y accountability; la innovación se materializa en 4V+ECD; y la implementación se traduce en un proceso de pilotaje y medición. De este modo, la propuesta mantiene coherencia entre propósito, tecnología, impacto y uso responsable.

9. Discusión, limitaciones y futuras líneas de investigación

9.1. Discusión

La revisión y la aplicación exploratoria sugieren que el debate sobre IAGen y trabajo profesional necesita superar dos simplificaciones. La primera es tratar exposición como sustitución. La segunda es suponer que toda automatización de trabajo junior conduce a deskilling. La evidencia muestra escenarios más complejos: la IA puede elevar productividad y acelerar el acceso a patrones expertos, pero también reorganizar las interacciones y experiencias mediante las que se construye expertise.

El 4V propone incorporar explícitamente este segundo horizonte en las decisiones de rediseño. Su principal aportación conceptual es VCE: reconocer que algunas tareas generan capacidades futuras y que esa función puede analizarse separadamente de su valor productivo. ECD añade granularidad al evitar una conclusión conservadora: no es necesario preservar la tarea completa si puede preservarse o sustituirse la experiencia que construye criterio.

Para Project Management, esta lógica resulta especialmente visible. Reporting, riesgos y lessons learned pueden tener alta automatizabilidad y, simultáneamente, alto VCE. Conflicto, alineamiento y excepciones tienen menor potencial de delegación completa y mayor VHD. La consecuencia no es dividir el puesto entre “IA” y “humano”, sino rediseñar secuencias de colaboración y progresión profesional.

9.2. Limitaciones

- El modelo no ha sido validado empíricamente. Las valoraciones de tareas son ilustrativas.
- La literatura sobre IAGen cambia rápidamente y parte de la evidencia disponible mide productividad a corto plazo más que retención de capacidades a largo plazo.
- VCE y ECD son constructos propuestos en este TFM; sus componentes tienen antecedentes sólidos, pero requieren operacionalización y validación específica.
- La aplicación se concentra en Project Management y no puede generalizarse automáticamente a derecho, finanzas, medicina, consultoría u otras profesiones.
- Las capacidades de los modelos evolucionan, por lo que VA debe actualizarse periódicamente.
- El modelo no incorpora por separado factores laborales macro como empleo, salarios, negociación colectiva o diseño de plantillas, aunque son relevantes para una implementación real.

9.3. Futuras líneas de investigación

La siguiente fase debería validar el modelo mediante métodos mixtos. Una encuesta podría medir VA, VHD, VCE, RD, frecuencia de uso e intensidad de delegación para un conjunto de tareas. Entrevistas a profesionales junior, mid y senior permitirían reconstruir qué experiencias contribuyeron realmente a su desarrollo y cómo están cambiando. Un diseño longitudinal sería especialmente valioso para distinguir mejora de desempeño asistido de adquisición de capacidad retenida.

También sería útil comparar modos de colaboración. Por ejemplo, asignar a grupos human-first, co-creación y AI-first en una misma tarea y medir no solo calidad inmediata, sino retención, transferencia y capacidad para detectar errores posteriores. Esta investigación permitiría convertir VCE y ECD en constructos mejor calibrados.

Finalmente, el 4V podría aplicarse a otros roles intensivos en conocimiento -legal, finanzas, procurement, recursos humanos, marketing, operaciones o consultoría- para explorar qué elementos son transversales y cuáles específicos de cada profesión.

10. Conclusiones

La IAGen está desplazando el debate organizativo desde la pregunta “¿puede una máquina hacer esta tarea?” hacia una cuestión más compleja: “¿cómo queremos distribuir el trabajo entre personas e IA y qué capacidades necesitamos conservar y desarrollar?”. La evidencia revisada muestra que la tecnología puede elevar productividad, especialmente entre trabajadores menos experimentados, pero que sus efectos dependen de la tarea y de la forma de integración. También muestra que la expertise se construye mediante oportunidades de práctica, feedback, reflexión y participación en situaciones reales.

El modelo 4V responde a esta complejidad evaluando cada tarea desde cuatro perspectivas: Viabilidad de Automatización, Valor Humano Diferencial, Valor de Construcción de Expertise y Riesgo de Delegación. La incorporación de VCE permite detectar tareas cuya automatización puede ser eficiente pero formativamente sensible. El concepto de ECD permite, a su vez, evitar un enfoque defensivo: el objetivo no es preservar tareas, sino preservar o rediseñar las experiencias que generan capacidades.

La aplicación exploratoria al Project Manager muestra que una misma profesión contiene perfiles de decisión muy diferentes. Algunas actividades de producción documental son candidatas claras a automatización; otras requieren co-creación; y aquellas ligadas a conflicto, excepciones, responsabilidad o contexto deben permanecer lideradas por humanos. Varias tareas altamente asistibles -reporting, riesgos, monitorización o lessons learned- pueden situarse en una Zona de Tensión Automatización-Expertise y requieren salvaguardas formativas.

La consecuencia práctica es que una organización madura no debería medir el éxito de la IA exclusivamente por horas ahorradas. Debería medir también si conserva personas capaces de comprender el trabajo, cuestionar los outputs, detectar excepciones, asumir responsabilidad y formar a la siguiente generación de profesionales. El éxito de la adopción de IA no debería evaluarse únicamente por la productividad que genera hoy, sino también por la capacidad profesional que permite conservar y desarrollar para mañana.

La propuesta requiere validación posterior, pero ofrece una base operativa para estructurar esa discusión. Frente a una adopción centrada únicamente en automatización, el 4V propone una lógica de rediseño: automatizar donde aporta valor, aumentar donde la colaboración es superior, mantener liderazgo humano donde el contexto y la responsabilidad lo exigen y

rediseñar el aprendizaje cuando la tecnología transforma las experiencias mediante las que se construye expertise.

Referencias

- Anseel, F., & Sherf, E. N. (2025). A 25-year review of research on feedback in organizations: From simple rules to complex realities. *Annual Review of Organizational Psychology and Organizational Behavior*, 12, 19-43. <https://doi.org/10.1146/annurev-orgpsych-110622-031927>
- Argote, L., & Miron-Spektor, E. (2011). Organizational learning: From experience to knowledge. *Organization Science*, 22(5), 1123-1137. <https://doi.org/10.1287/orsc.1100.0621>
- Beane, M., & Anthony, C. (2024). Inverted apprenticeship: How senior occupational members develop practical expertise and preserve their position when new technologies arrive. *Organization Science*, 35(2), 405-431. <https://doi.org/10.1287/orsc.2023.1688>
- Brynjolfsson, E., Li, D., & Raymond, L. R. (2025). Generative AI at work. *The Quarterly Journal of Economics*, 140(2), 889-942. <https://doi.org/10.1093/qje/qjae044>
- Cui, K. Z., Demirer, M., Jaffe, S., Musolff, L., Peng, S., & Salz, T. (2026). The effects of generative AI on high-skilled work: Evidence from three field experiments with software developers. *Management Science*. <https://doi.org/10.1287/mnsc.2025.00535>
- Dell'Acqua, F., McFowland III, E., Mollick, E., Lifshitz, H., Kellogg, K. C., Rajendran, S., Kraye, L., Candelon, F., & Lakhani, K. R. (2026). Navigating the jagged technological frontier: Field experimental evidence of the effects of artificial intelligence on knowledge worker productivity and quality. *Organization Science*, 37(2), 403-423. <https://doi.org/10.1287/orsc.2025.21838>
- Dillon, E., Jaffe, S., Immorlica, N., & Stanton, C. (2025). Shifting work patterns with generative AI (NBER Working Paper No. 33795). National Bureau of Economic Research. <https://doi.org/10.3386/w33795>
- Eraut, M. (2004). Informal learning in the workplace. *Studies in Continuing Education*, 26(2), 247-273. <https://doi.org/10.1080/158037042000225245>
- Ericsson, K. A., Krampe, R. T., & Tesch-Römer, C. (1993). The role of deliberate practice in the acquisition of expert performance. *Psychological Review*, 100(3), 363-406. <https://doi.org/10.1037/0033-295X.100.3.363>
- Fuller, A., & Unwin, L. (2003). Learning as apprentices in the contemporary UK workplace: Creating and managing expansive and restrictive participation. *Journal of Education and Work*, 16(4), 407-426. <https://doi.org/10.1080/1363908032000093012>
- Gmyrek, P., Berg, J., Kamiński, K., Konopczyński, F., Ładna, A., Nafradi, B., Rosłaniec, K., & Troszyński, M. (2025). Generative AI and jobs: A refined global index of occupational exposure (ILO Working Paper 140). International Labour Organization. <https://doi.org/10.54394/HETP0387>
- Felicetti, A. M., Cimino, A., Mazzoleni, A., & Ammirato, S. (2024). Artificial intelligence and project management: An empirical investigation on the appropriation of generative chatbots by project managers. *Journal of Innovation & Knowledge*, 9(3), 100545. <https://doi.org/10.1016/j.jik.2024.100545>

- Kellogg, K. C., Lifshitz, H., Randazzo, S., Mollick, E., Dell'Acqua, F., McFowland III, E., Candelon, F., & Lakhani, K. R. (2025). Novice risk work: How juniors coaching seniors on emerging technologies such as generative AI can lead to learning failures. *Information and Organization*, 35(1), 100559. <https://doi.org/10.1016/j.infoandorg.2025.100559>
- Li, K., Zhang, F., Hughes, L., & Griffin, M. A. (2026). Leveraging generative AI for project management: The role of mindfulness and job crafting. *International Journal of Project Management*, 44(2), 102816. <https://doi.org/10.1016/j.ijproman.2026.102816>
- Macnamara, B. N., Hambrick, D. Z., & Oswald, F. L. (2014). Deliberate practice and performance in music, games, sports, education, and professions: A meta-analysis. *Psychological Science*, 25(8), 1608-1618. <https://doi.org/10.1177/0956797614535810>
- Noy, S., & Zhang, W. (2023). Experimental evidence on the productivity effects of generative artificial intelligence. *Science*, 381(6654), 187-192. <https://doi.org/10.1126/science.adh2586>
- Project Management Institute. (2026). *The Standard for Artificial Intelligence in Portfolio, Program and Project Management*. PMI.
- Rousseau, D. M., & Stouten, J. (2025). Experts and expertise in organizations: An integrative review on individual expertise. *Annual Review of Organizational Psychology and Organizational Behavior*, 12, 159-184. <https://doi.org/10.1146/annurev-orgpsych-020323-012717>
- Savelsbergh, C. M. J. H., Havermans, L. A., & Storm, P. (2016). Development paths of project managers: What and how do project managers learn from their experiences? *International Journal of Project Management*, 34(4), 559-569. <https://doi.org/10.1016/j.ijproman.2016.02.005>
- Tannenbaum, S. I., & Wolfson, M. A. (2022). Informal (field-based) learning. *Annual Review of Organizational Psychology and Organizational Behavior*, 9, 391-414. <https://doi.org/10.1146/annurev-orgpsych-012420-083050>

Anexo A. Matriz exploratoria de tareas de Project Management

La siguiente matriz resume el uso posible del modelo 4V. Debe interpretarse como ejemplo de aplicación y no como resultado empírico. En una aplicación real, cada valoración debería justificarse con evidencia de proceso, experiencia de los titulares del puesto, datos de calidad y riesgo y características concretas de la tecnología utilizada.

#	Tarea	ECD potenciales	Capacidades desarrolladas
1	Definir alcance y objetivos	Traducir ambigüedad; negociar inclusiones/exclusiones; resolver expectativas	Problem framing, priorización, negociación, comprensión de negocio
2	Descomponer y planificar	Convertir objetivos en trabajo; descubrir dependencias	Pensamiento sistémico, estructuración, causalidad
3	Cronograma	Secuenciar; observar retrasos y efectos	Anticipación, dependencias, comprensión temporal
4	Estimaciones	Formular supuestos; comparar previsión y realidad	Calibración, incertidumbre, juicio
5	Recursos	Contrastar disponibilidad formal y real; negociar prioridades	Lectura organizativa, negociación, priorización
6	Progreso/desviaciones	Detectar señales; diagnosticar causas	Diagnóstico, patrones, causalidad
7	Status reporting	Seleccionar relevancia; decidir escalado	Síntesis, interpretación, comunicación ejecutiva
8	Reuniones/acciones	Observar dinámicas; identificar compromisos	Atención contextual, stakeholders, accountability
9	Riesgos	Imaginar escenarios; revisar aciertos/omisiones	Anticipación, pensamiento probabilístico, sistemas
10	Incidencias/excepciones	Diagnosticar y resolver problemas reales	Problem solving, criterio contextual, autonomía
11	Cambios	Evaluar impactos cruzados y trade-offs	Pensamiento sistémico, decisión multidimensional
12	Comunicación stakeholders	Adaptar mensaje y observar reacciones	Influencia, comunicación contextual
13	Expectativas/alineamiento	Hacer explícitos intereses y desacuerdos	Confianza, negociación, lectura política
14	Conflictos	Gestionar intereses incompatibles	Negociación, regulación emocional, juicio relacional
15	Lessons learned	Relacionar decisión, resultado y causa	Reflexión, metacognición, actualización de modelos mentales